

MUSIC MOOD ACTIVITY RECOMMENDER

Intelligent Music Recommendation System based on
Context, Emotion, and Machine Learning



Índice

1. Del Lenguaje Humano a la Recomendación Musical	3
1.1. El Puente entre la Palabra y la Acción: El Problema de la Ambigüedad	3
1.2. La Anatomía del Intérprete: Un Enfoque Híbrido	3
1.3. La Traducción: De Etiquetas a Dimensiones Musicales	4
1.4. El Mapa de Familias y Perfiles	4
1.5. El Cerebro del Recomendador: Generación del "Score"	5
1.6. La Experiencia Final: De la Lógica a la Pantalla	5
2. Guía sobre el Ciclo de Vida del Dato (Capas Bronze, Silver y Gold)	6
2.1. Introducción: La Alquimia de los Datos Musicales	6
2.2. La Capa Bronze: El Punto de Entrada (Datos en Bruto)	6
2.3. La Capa Silver: La Refinería de Spark	7
2.4. La Capa Gold: El Tesoro Preparado para la IA	8
2.5. El Ecosistema de Soporte: Los Guardianes del Dato.....	9
3. Protocolo de Modelado: Sistema de Recomendación Emocional y Contextual.....	9
3.1. Estrategia de Preparación de Datos y Calidad de la Capa Gold.....	9
3.2. Clasificación Multiclase: De la Referencia Lineal al Bosque Aleatorio.....	11
3.3. El Intérprete de Actividad: Procesamiento de Lenguaje y Reglas de Negocio .	12
3.4. Recomendador Contextual mediante Weak Supervision.....	12
3.5. Gestión de Artefactos y Prevención de Leakage.....	13
4. Arquitectura de Extracción de Datos y APIs.....	13
4.1. Justificación de la API de Extracción (SoundNet)	13
4.2. Características y Costes de la API	14
4.3. Flujo de Integración: API, Interfaz y Modelo	14
5. Despliegue.....	14
5.1. Interfaz y Despliegue en AWS EC2.....	14
6. Manual de Usuario (Interfaz Gradio)	15
6.1. Módulo Recomendador	15
6.2. Módulo de Clasificación en Tiempo Real (Ingesta).....	16

1. Del Lenguaje Humano a la Recomendación Musical

1.1. El Puente entre la Palabra y la Acción: El Problema de la Ambigüedad

Como Arquitecto de Aprendizaje en IA, entiendo que la música no es un producto estático, sino una experiencia intrínsecamente ligada al contexto. El desafío fundamental reside en que las etiquetas emocionales tradicionales (mood) son insuficientes para capturar la complejidad de la intención humana. El sistema debe operar bajo un paradigma de recomendación contextual, donde el estado de ánimo se orquesta con la actividad del usuario para resolver la necesidad auditiva real.

- **Más allá del "Mood" Estático:** Clasificar una pieza como "triste" o "feliz" ignora que la música cumple funciones reguladoras. Un usuario puede estar triste pero requerir energía para entrenar, lo que exige un modelo capaz de balancear señales contradictorias en un espacio latente común.
- **La Recomendación Contextual:** No buscamos una coincidencia exacta de etiquetas, sino una compatibilidad dinámica. La arquitectura debe unir el "sentir" con el "hacer", transformando una emoción declarada y una actividad descrita en un vector de intención único.
- **La Intención tras el Lenguaje Natural:** El lenguaje humano es libre y no estructurado. El sistema debe descifrar frases como "tengo que concentrarme para el examen" no solo como texto, sino como una solicitud técnica de parámetros acústicos específicos.

Transición: Para procesar esta intención, el sistema activa un pipeline de inferencia en cascada que comienza con la disección anatómica de la frase del usuario.

1.2. La Anatomía del Intérprete: Un Enfoque Híbrido

Para convertir lenguaje natural en datos accionables, el sistema emplea una arquitectura de dos capas. Este enfoque asegura la flexibilidad del aprendizaje lingüístico sin perder la precisión necesaria en casos de uso críticos.

Componente	Función	Ejemplo de uso
Modelo de Texto (NLP)	Clasifica frases libres en "familias" de actividad mediante el aprendizaje de representaciones semánticas.	"Voy a prepararme algo de cenar".

Reglas por Palabras Clave	Mapeo heurístico que garantiza la asignación inmediata de términos específicos a familias predefinidas.	"Comer" o "Cenar" = <i>Alimentación.</i>
---------------------------	---	--

1.3. La Traducción: De Etiquetas a Dimensiones Musicales

Una vez identificada la familia de actividad, el sistema realiza un proceso de feature engineering inverso. Los datos, procesados mediante Spark y almacenados en las capas Silver y Gold de nuestro Data Lake en S3, permiten traducir una intención en un vector numérico de seis parámetros clave:

- **Movimiento:** Cadencia rítmica necesaria; alta para cardio, mínima para el descanso.
- **Energía:** Intensidad sonora; fundamental para la limpieza o el entrenamiento intenso.
- **Positividad:** Nivel de valencia; ajusta si la recomendación debe ser eufórica o melancólica.
- **Foco:** Parámetro crítico derivado de una baja speechiness; busca minimizar la presencia de voz para favorecer procesos cognitivos profundos.
- **Calma:** Estabilidad rítmica y ausencia de elementos disruptores.
- **Acousticness:** Preferencia por texturas orgánicas, vital para momentos de introspección o relajación.

Adicionalmente, el sistema integra una capa de enriquecimiento de letras (lexicon rates), extrayendo señales de tristeza, felicidad o energía directamente del contenido textual de las canciones, lo que añade una dimensión semántica al perfil acústico.

Transición: Estos parámetros constituyen el lenguaje técnico que el motor de recomendación utiliza para puntuar el catálogo.

1.4. El Mapa de Familias y Perfiles

El sistema mapea frases reales a comportamientos técnicos mediante perfiles musicales pre-calculados. Este diseño permite que la arquitectura maneje frases "nunca vistas" asignándolas a la familia semántica más coherente:

1. **Alimentación (comer, cenar):** Mapea a un perfil de calma media y energía baja; busca acompañar el ritual sin saturar el espacio sonoro.
2. **Actividad Física (gym, correr):** Exige niveles máximos de energía y movimiento, priorizando tracks con alto tempo y baja calma.

3. Estudio/Trabajo (estudiar, trabajar): Maximiza el foco mediante la penalización estricta de la *speechiness* y el refuerzo de la calma.
4. Desahogo (llorar, desahogarme): Genera un perfil de baja energía y positividad, permitiendo que la música actúe como espejo del estado introspectivo.

Transición: Estos perfiles alimentan el "cerebro" del recomendador, donde se produce el cálculo final de relevancia.

1.5. El Cerebro del Recomendador: Generación del "Score"

Dado que no existe un dataset etiquetado masivo que relacione cada actividad humana con canciones específicas, implementamos Supervisión Débil (Weak Supervision). Utilizamos reglas heurísticas musicales para generar etiquetas "Gold" de entrenamiento, permitiendo que modelos de regresión aprendan la función de puntuación ideal. El sistema utiliza RandomForestRegressor o MLPRegressor para generar un *score* continuo de 0 a 1:

- Características acústicas: Extraídas del catálogo en S3 (danceability, tempo, etc.).
- Probabilidades emocionales: Salidas discretas del clasificador de *mood* (sad, happy, energetic, calm).
- Estado emocional del usuario: Señal directa de la interfaz.
- Perfil numérico de la actividad: Vector generado por el intérprete de texto.
- Señales de Lyrics: Tasas léxicas (sad/happy rate) que refinan la clasificación acústica.

Transición: Tras procesar esta "coctelera" de datos, el sistema orquesta la salida hacia la interfaz de usuario.

1.6. La Experiencia Final: De la Lógica a la Pantalla

La arquitectura culmina en una interfaz unificada sobre FastAPI y Gradio, donde la complejidad del pipeline de inferencia se oculta tras una experiencia visual limpia y transparente.

- [x] Tarjetas de resultados: Visualización clara de metadatos y portadas.
- [x] Reproductor integrado (Spotify Iframe): Escucha inmediata para validación del usuario.
- [x] Tags de predicción: Transparencia algorítmica que explica el porqué de la recomendación.

- [x] Enlace directo a Spotify: Conexión con el ecosistema musical completo del usuario.

Transición: El sistema queda así preparado para el siguiente nivel evolutivo: la integración de un bucle de feedback (like/dislike) para el refinamiento continuo de los pesos del modelo.

2. Guía sobre el Ciclo de Vida del Dato (Capas Bronze, Silver y Gold)

2.1. Introducción: La Alquimia de los Datos Musicales

En un ecosistema de producción, los eventos generados por el consumo musical son volátiles y desestructurados. Para transformar este flujo caótico en conocimiento accionable, implementamos un **Data Lake**: un repositorio centralizado que permite almacenar vastas cantidades de datos en su formato natural y procesarlos mediante una arquitectura de capas.

Este proceso debe entenderse como una **refinería de datos**. Así como el petróleo crudo requiere etapas de destilación para convertirse en combustible de alto octanaje, los eventos brutos de una canción (como su energía o tempo) deben ser refinados para alimentar algoritmos de recomendación. Sin esta "alquimia" técnica, el modelo de IA solo procesaría ruido; con ella, transformamos señales eléctricas en emociones.

Los tres pilares fundamentales de este ciclo son:

- **Calidad:** Garantizar la integridad mediante el tipado estricto y la imputación de valores.
- **Trazabilidad:** Registrar el linaje del dato desde la ingesta en Kafka hasta su estado final en S3.
- **Escalabilidad:** Separar el cómputo del almacenamiento para permitir el crecimiento exponencial del catálogo.

Con los cimientos establecidos, iniciamos el recorrido en el estrato más profundo de nuestra arquitectura: la verdad del dato en bruto.

2.2. La Capa Bronze: El Punto de Entrada (Datos en Bruto)

La **Capa Bronze** representa la zona de aterrizaje del ecosistema. Aquí, los datos son ingeridos directamente desde **Apache Kafka**, que actúa como el bus de eventos encargado de desacoplar las fuentes de origen del procesamiento posterior.

En esta fase, la misión del arquitecto es **preservar la verdad original**. Los datos se almacenan en formato **JSONL** (JSON Lines), una elección estratégica que permite la escritura incremental y flexible, garantizando que cada evento se registre tal cual fue capturado. No se aplican filtros ni transformaciones: cualquier limpieza en este punto comprometería la capacidad de auditoría y re-procesamiento.

Matriz de Ingesta

Característica	Fuente de Origen (Kafka)	Destino (S3 Bronze)
Identidad	Flujo de eventos en tiempo real	Persistencia de la "Verdad Cruda"
Formato	Serialización de mensajes	s3://<bucket>/bronze/*.jsonl
Estado	Volátil y efímero	Inmutable y persistente
Gobernanza	Desacoplamiento de sistemas	Histórico para recuperación de desastres

Principio de Arquitectura: Mantener el dato "sucio" en Bronze es una póliza de seguro. Si el pipeline de limpieza falla o las reglas de negocio cambian, la Capa Bronze permite reconstruir todo el Data Lake sin pérdida de información original.

Asegurada la persistencia, el dato crudo se traslada a la refinería para adquirir estructura y sentido.

2.3. La Capa Silver: La Refinería de Spark

En la **Capa Silver**, el motor de procesamiento distribuido **Apache Spark** ejecuta la transformación técnica. Un detalle crítico de implementación es que Spark descarga los datos a una **carpeta temporal local** para su procesamiento antes de realizar la carga final a S3. Aquí, el dato transita de la flexibilidad del JSONL a la eficiencia del formato **Parquet**.

Para alcanzar el estándar de la Capa Silver, el arquitecto aplica cuatro acciones de limpieza obligatorias:

1. **Tipado Estricto:** Conversión de características musicales a formatos numéricos precisos (**Double/Float**) y etiquetas de destino a enteros (**Int**).
2. **Normalización de Esquema:** Estandarización de nombres de columnas y eliminación de metadatos irrelevantes de la fuente original.
3. **Deduplicación:** Eliminación de registros repetidos utilizando el track_id como clave de integridad.

4. **Eliminación de registros con valores nulos:** En datasets musicales no interesa imputar features ya que simplemente distorcionaría las recomendaciones y clasificaciones de los tracks.

Evolución Técnica del Almacenamiento

Atributo	JSONL (Bronze)	Parquet (Silver)
Orientación	Basado en filas (Texto)	Columnar (Binario)
Compresión	Baja (Lectura pesada)	Alta (Optimizado para S3)
Esquema	Implícito (Schema-on-read)	Explícito y tipado
Justificación	Ingesta continua	Eficiencia en analítica y ML

Con una base de datos limpia y consistente, estamos preparados para generar el "oro" que consumirán nuestros modelos de Machine Learning.

2.4. La Capa Gold: El Tesoro Preparado para la IA

La **Capa Gold** es el estadio de especialización donde los datos se segmentan en datasets específicos: **Mood**, **Tracks** y **Lyrics**. En esta etapa, el procesamiento se enfoca en la compatibilidad matemática con los modelos de IA.

Protocolo de Preparación Final:

- [] **Escalado (Z-score):** Normalización de características (energía, tempo, etc.) utilizando la media y desviación estándar calculadas **exclusivamente sobre el dataset de Mood**, aplicando luego estas estadísticas a Tracks y Lyrics para garantizar rangos compatibles.
- [] **Ingeniería de Señales de Lyrics:** El texto completo se descarta por ineficiencia. En su lugar, se generan 6 señales numéricas ligeras: lyrics_length, lyrics_word_count y los ratios léxicos para sad, happy, energetic y calm.
- [] **Tratamiento de Outliers:** Aplicación de *clipping* por IQR para mitigar el impacto de valores extremos únicamente en columnas que lo requieran como el tempo, duración_ms y loudness, al resto de features no se les aplica ya que son valores que van de 0 a 1.
- [] **Split Estratificado (80/20):** División en entrenamiento y prueba. Es vital que este split sea estratificado para compensar el **desbalance de clases**, ya que la categoría happy es significativamente mayor que la categoría calm.

Nota de Implementación: En Gold, los datos de "lyrics" dejan de ser lenguaje natural para convertirse en vectores numéricos. Esto permite que el recomendador analice la carga emocional de una letra con la misma velocidad que procesa un bit de audio.

Este flujo de alta precisión requiere de una infraestructura de vigilancia que garantice que ningún engranaje falle.

2.5. El Ecosistema de Soporte: Los Guardianes del Dato

La integridad del Data Lake no depende solo del procesamiento, sino de los servicios que auditan y catalogan la información:

- **AWS Glue/Athena:** El catálogo y la lupa (validación SQL). Permiten consultar `s3://<bucket>/gold/` mediante SQL estándar sin mover los datos.
 - **AWS RDS (MySQL):** El diario de abordó (trazabilidad de ejecuciones). Registra de forma tabular qué pipeline se ejecutó, cuántas filas se procesaron y el `storage_path` resultante.
 - **MongoDB Atlas:** El archivador flexible (metadatos de archivos). Almacena metadatos granulares (como tamaños de row groups en Parquet) que, debido a su naturaleza semiestructurada, no encajan en el esquema rígido de RDS.
 - **AWS Lambda:** El centinela (auditoría automática por eventos). Se dispara ante cada escritura en S3 para verificar la integridad del objeto y registrar el evento de auditoría.
-

La arquitectura de almacenamiento se sintetiza en el siguiente flujo de valor:

Kafka (Evento) → S3 Bronze (Verdad) → Spark (Refinería Local) → S3 Silver (Limpio) → ML Prep (Gold) → S3 Gold (IA Ready)

3. Protocolo de Modelado: Sistema de Recomendación Emocional y Contextual

3.1. Estrategia de Preparación de Datos y Calidad de la Capa Gold

La transición de datos de la capa Silver a la Gold no es una mera transformación de formato, sino un proceso de refinamiento estratégico donde la integridad de la información condiciona el éxito de los modelos predictivos. En esta fase, el objetivo principal es mitigar riesgos de sesgo y asegurar que el "ruido" de los datos crudos no degrade la capacidad de generalización del sistema.

Análisis de Deduplicación y Mitigación de Riesgos

La implementación de la estrategia `--split-strategy deduplicated` es un guardrail arquitectónico crítico. Se detectó que el conjunto de datos original contenía registros con combinaciones de variables acústicas idénticas; sin esta deduplicación, el modelo incurriría en una "fuga de información" (*data leakage*), obteniendo métricas de rendimiento artificialmente altas al "memorizar" datos en lugar de aprender patrones. Se aplica un split estratificado 80/20 para contrarrestar el desbalance severo en clases minoritarias como 'calm', garantizando que la validación sea estadísticamente representativa.

Transformación de Features y Prevención de Fugas

Las transformaciones aplicadas buscan la estabilidad de los algoritmos de aprendizaje clásico mediante el control de la varianza y la escala:

Transformación	Método Aplicado	Impacto en el Modelo / Nota de Implementación
Tratamiento de Outliers	Clipping por rango IQR ($Q1 - 1.5IQR$ a $Q3 + 1.5IQR$) a determinadas columnas como tempo, loudness, y duration_ms	Neutraliza el impacto de valores extremos sin pérdida de volumen de registros.
Escalamiento	Z-score (StandardScaler)	Normaliza dimensiones. Nota: Los scaler_stats se derivan estrictamente del set de entrenamiento Gold para evitar fugas hacia el catálogo de tracks.
Tratamiento de Nulos	Eliminación de registros con valores nulos	Garantiza la robustez del modelo

Enriquecimiento Semántico: Señales de Lyrics

Para optimizar la eficiencia computacional y la latencia en tiempo real, se evita el procesamiento de texto completo del lyrics_dataset. En su lugar, se inyectan señales ligeras (*lexicon rates*), transformando el contenido textual en tasas de frecuencia emocional (sad, happy, energetic, calm). Esto dota al modelo de una ventaja competitiva al integrar semántica sin la carga técnica de un motor de NLP pesado.

3.2. Clasificación Multiclase: De la Referencia Lineal al Bosque Aleatorio

El núcleo del sistema emplea un enfoque de clasificación supervisada multiclase para mapear vectores acústicos a cuatro estados de ánimo fundamentales (*sad*, *happy*, *energetic*, *calm*).

Evaluación de Modelos y Justificación Técnica

Se establecieron dos benchmarks para determinar la arquitectura óptima:

- **Regresión Logística (Baseline):** Aunque ofreció una interpretabilidad inmediata y un Accuracy de 0.79, resultó insuficiente para capturar las fronteras de decisión no lineales en el espacio de características musicales.
- **Random Forest (Estándar de Producción):** Seleccionado por su superioridad en el manejo de relaciones complejas. Alcanzó un Accuracy de 0.86 y un F1-macro de 0.63, demostrando una robustez significativamente mayor en el set de pruebas deduplicado.

Optimización y Guardrails de Hiperparámetros

Mediante GridSearchCV, se priorizó la optimización del f1_macro sobre el Accuracy simple. Una pieza clave de la arquitectura fue la inclusión del parámetro `class_weight="balanced"`, una medida correctiva esencial para que el bosque aleatorio pueda discriminar eficazmente la clase 'calm' (la cual contaba con una representación mínima en el dataset de entrenamiento).

Importancia de Variables (Feature Importance)

El análisis de relevancia revela los pilares semánticos del modelo:

1. **Energy (0.2380):** El discriminador primario entre estados activos y pasivos.
2. **Danceability (0.1718):** Define la estructura rítmica y positividad.
3. **Acousticness (0.1259):** Crucial para separar producciones orgánicas de sintéticas.
4. **Loudness (0.1061):** Indicador de intensidad emocional.
5. **Speechiness (0.1027):** Diferencia entre contenido musical y vocal (foco).

3.3. El Intérprete de Actividad: Procesamiento de Lenguaje y Reglas de Negocio

Para dotar de relevancia a la sugerencia, el sistema debe interpretar semánticamente el contexto del usuario a través de una metodología híbrida.

Metodología de Interpretación y Refinamiento

El intérprete combina modelos de clasificación de texto con un motor de reglas de palabras clave. Como medida de seguridad, se implementa un mecanismo de "fall-back": ante una baja confianza en la clasificación del texto libre, el sistema recurre a la etiqueta más próxima según el perfil musical histórico del usuario.

Mapeo de Dimensiones Musicales por Actividad

- Gym / Correr: Alta energía, alta rítmica (danceability), baja calma.
- Estudio / Trabajo: Máximo foco, alta calma, mínima presencia vocal (speechiness).
- Limpieza Doméstica: Energía moderada, movimiento constante.
- Alimentación: Calma media, energía controlada, ambiente acústico.

Estos vectores de actividad permiten que el sistema transforme una frase humana en una consulta numérica para el recomendador.

3.4. Recomendador Contextual mediante Weak Supervision

La transición estratégica de una clasificación discreta a una puntuación continua de afinidad (0-1) se resuelve mediante modelos de regresión (MLP o Random Forest Regressor) según el mejor que a resultado en el proceso de entrenamiento.

Mitigación de Cold-Start: Weak Supervision

Ante la ausencia inicial de feedback real de usuarios (likes/dislikes), se aplica Weak Supervision (Supervisión Débil). Esta técnica de Cold-Start Mitigation utiliza heurísticas musicales para generar etiquetas de entrenamiento iniciales, permitiendo que el modelo aprenda reglas de negocio complejas (ej. priorizar música enérgica para un usuario triste que va al gimnasio) antes de recibir datos de interacción real.

Arquitectura de Entrada del Recomendador (Jerarquía de Señales)

El recomendador procesa un vector de características concatenado que sigue esta jerarquía:

- Nivel 1: Atributos Acústicos Base (Features del track de Spotify).

- Nivel 2: Señales de Probabilidad Emocional (Output del clasificador multiclase).
- Nivel 3: Perfil del Contexto de Usuario
 - *Dimensiones Musicales de la Actividad* (Energía, Movimiento, Foco, Calma).
 - *Estado Emocional Declarado*.

Este diseño permite resolver conflictos contextuales y generar un ranking de afinidad preciso. Las métricas de regresión del hito (MAE, RMSE, R2) se utilizan como controles técnicos para verificar que el modelo está asimilando correctamente las reglas de la supervisión débil.

3.5. Gestión de Artefactos y Prevención de Leakage

El pipeline de producción persiste los siguientes archivos .joblib:

- `mood_best_model.joblib`: Clasificador emocional multiclase.
- `recommender_best_model.joblib`: Motor de scoring (MLP/RF).
- `activity_interpreter`: Modelo híbrido de NLP.
- `scaler_stats`: Parámetros de normalización calculados solo en el set de entrenamiento para garantizar la consistencia en inferencia sin fuga de datos.

4. Arquitectura de Extracción de Datos y APIs

4.1. Justificación de la API de Extracción (SoundNet)

Para que el sistema de recomendación y clasificación pueda operar en tiempo real con nuevas canciones, es imprescindible extraer los descriptores acústicos (conocidos como *Audio Features: danceability, energy, valence*, etc.) de cada pista. Históricamente, esta extracción se realizaba de forma gratuita a través del endpoint `/v1/audio-features` de la API oficial de Spotify.

Sin embargo, debido a recientes cambios en las políticas de uso de Spotify, este endpoint ha sido bloqueado y deprecado para las nuevas aplicaciones registradas, manteniendo el acceso exclusivamente para desarrolladores con cuentas antiguas. Ante esta limitación técnica que impedía la escalabilidad del proyecto, se ha optado por integrar una solución de terceros a través de RapidAPI: el proveedor SoundNet (`track-analysis.p.rapidapi.com`).

4.2. Características y Costes de la API

La integración de SoundNet presenta las siguientes características dentro del proyecto:

- **Modelo de facturación Freemium:** La API es de pago, pero ofrece una capa gratuita (Free Tier) que permite realizar hasta 5 peticiones diarias sin coste, un volumen suficiente para realizar las pruebas de concepto y la validación del TFG.
- **Consistencia del Espacio Vectorial:** La razón fundamental para elegir este proveedor es que utiliza el mismo sistema de análisis algorítmico que los datos empleados para el entrenamiento original del modelo clasificador. La API devuelve los valores que posteriormente debo adaptar mediante una normalización en el rango unitario (0.0 a 1.0) para métricas como *speechiness*, *acousticness* o *instrumentalness*. Esto garantiza que no exista "Data Drift" (deriva de datos) y que el modelo interprete las nuevas canciones con la misma precisión que las del dataset de entrenamiento.

4.3. Flujo de Integración: API, Interfaz y Modelo

Una vez que el usuario interactúa con la aplicación, el flujo de datos se orquesta de la siguiente manera:

1. **Extracción:** Se envía la URL de Spotify a la API de SoundNet, la cual devuelve el vector de características acústicas en crudo.
2. **Intervención Humana (Gradio):** Estos valores se inyectan en los controles deslizantes (*sliders*) de la interfaz Gradio. Esto permite al usuario validar los datos.
3. **Inferencia e Ingesta:** Las características finales (ya sean las de la API o las ajustadas por el usuario) se envían al RealtimeMoodClassifier. El modelo estandariza los datos, predice el *mood* de la canción y añade la nueva fila al catálogo de forma asíncrona mediante una estrategia *Append-Only* para estar inmediatamente disponible en el recomendador.

5. Despliegue

5.1. Interfaz y Despliegue en AWS EC2

La capa de presentación converge en una solución web unificada mediante FastAPI, integrando interfaces de Gradio para el Recomendador Contextual y el Clasificador Realtime.

- **Infraestructura:** Despliegue en instancias EC2 (Amazon Linux 2023) tipo t3.medium.
- **Automatización:** El despliegue se realiza mediante scripts que utilizan URLs prefirmadas de S3 para la descarga segura del paquete de aplicación, eliminando la gestión manual de roles IAM complejos en el host.
- **Persistencia del Servicio:** La aplicación se gestiona como un servicio de sistema mediante systemd (music-mood-web), asegurando que el proceso Uvicorn sea resiliente a reinicios y fallos críticos.

La capacidad de extraer *audio features* en tiempo real vía API de Spotify/OEmbed transforma el sistema. Ya no es un proceso estático; cualquier canción nueva añadida por un usuario se clasifica e integra instantáneamente en el catálogo de recomendaciones, cerrando el ciclo de vida del dato en vivo.

6. Manual de Usuario (Interfaz Gradio)

La aplicación web cuenta con dos módulos principales desarrollados con Gradio, diseñados para separar la ingesta de datos del consumo de recomendaciones.

6.1. Módulo Recomendador

Esta es la interfaz principal orientada al usuario final, donde el Procesamiento de Lenguaje Natural (NLP) se cruza con las métricas musicales.

Pasos de uso:

1. **Definir el Estado Emocional:** El usuario selecciona cómo se siente en ese momento a través de un desplegable (Triste, Feliz, Enérgico o Tranquilo).
2. **Describir la Actividad:** En la caja de texto libre "*¿Qué actividad o momento tienes ahora?*", el usuario debe escribir su contexto actual (ej. "*quiero llorar*", "*voy a fregar el suelo*", "*voy al gym*"). El intérprete lingüístico del sistema traducirá esta frase en necesidades de energía, movimiento y foco.
3. **Filtros Opcionales:** Se pueden acotar los resultados introduciendo un Artista específico o seleccionando un Género musical del catálogo.
4. **Obtener Recomendaciones:** Al pulsar "Buscar canciones", el sistema lee el catálogo actualizado, evalúa cada canción generando un *Score* de recomendación y muestra las X mejores coincidencias en formato de tarjetas

visuales, incluyendo un reproductor integrado de Spotify y opción de escuchar en spotify.

5. Navegar opciones: Si el usuario desea otras alternativas bajo los mismos parámetros, el botón secundario "Refrescar opciones" descarta las pistas ya mostradas y recupera un nuevo set de canciones adecuadas del catálogo en memoria.
6. Un filtro de puntuación: Podemos indicar al recomendador entre que rangos de recomendación quiero que se me muestren los resultados con el objetivo de poder decidir como de preciso queremos que sea el recomendador.

6.2. Módulo de Clasificación en Tiempo Real (Ingesta)

Este módulo permite alimentar el catálogo del sistema con nuevas canciones bajo demanda.

Pasos de uso:

1. Pestaña "Track Individual": En la caja de texto etiquetada como *URL Spotify del track*, el usuario debe pegar el enlace de la canción que desea añadir al sistema.
2. Analizar URL: Al pulsar el botón "Analizar URL", el sistema realiza la petición a la API y autocompleta los metadatos (Nombre, Artista, Género) y ajusta los *sliders* de las características acústicas (Danceability, Energy, Tempo, etc.) con los valores reales de la canción.
3. Clasificación: Al pulsar "Clasificar y añadir al catálogo", el modelo procesa la información y devuelve una tarjeta con la canción, mostrando el *mood* detectado (ej. *Happy* o *Sad*) y el porcentaje de confianza de la predicción. La canción queda instantáneamente guardada en la base de datos de recomendaciones.

Nota: También dispone de una pestaña "Dataset" para subir archivos .csv o .parquet y realizar clasificaciones masivas (Batch processing).